



UNIVERSITÉ D'ANTANANARIVO
FACULTÉ DES SCIENCES ET TECHNOLOGIES
Mention : Mathématiques et Informatique
Parcours : Mathématiques Appliquées
Spécialité : Combinatoire et Optimisation



RAPPORT DE T.P SUR L'ANALYSE DE DONNÉES

Analyse en Composantes Principales (A.CP.) sur un jeu de données
d'une Banque.

Étudiant : Jean René RANDRIANJAKAMANANA

Date : 16 septembre 2024

Enseignant : Dr. Joseph RAKOTONDRALAMBO

Année Universitaire : 2023-2024

Tables de matières

Analyse en Composantes Principales (A.C.P)	2
I) INTRODUCTION	2
II) BUTS	3
III) ETAPES	3
1) Etape 1: Importation et description des données	4
2) Etape: Analyse des corrélations entre les variables actives	7
3) Etape 3: Standardisation des données	8
4) Etape 4: Réalisation de l'ACP avec FactoMineR	9
IV) ANALYSE DES VARIABLES	11
1) Choix du nombre d'axe factoriel	11
3) Coordonnées des variables sur les axes	13
4) Cos2 des variables	13
4) Contribution des variables	14
5) Représentation du cercle de corrélation sur le premier plan factoriel	16
V) ANALYSE DES INDIVIDUS	19
1) Coordonnées des individus sur les axes	19
3) Cos2 des individus	19
3) Contribution des individus	20
4) Représentation des individus sur le premier plan factoriel	22
VI) SUPERPOSITION DES INDIVIDUS ET VARIABLES	23
CONCLUSION	24
VII) AJOUT DES VARIABLES SUPPLEMENTAIRES	25
1) ACP avec les variables supplémentaires	25
2) Qualité de représentations:	27
2) Tests de corrélations entre les variables et axes	27

Analyse en Composantes Principales (A.C.P)

I) INTRODUCTION

Dans ce T.P, on procède à l'analyse d'un jeu de données d'une certaine banque telle que les variables utilisées sont les suivantes:

- SOLD: Solde moyen du compte courant (en Francs). (L'abréviation-ici SOLD - est utilisée pour désigner la variable lors des traitements informatiques et des analyses statistiques).
- CHEQ: Montant moyen des chèques tirés lors du dernier semestre (en F.).
- NDEC: Nombre de mois avec découvert sur le compte courant lors de l'année précédente.
- MDEC: Montant cumulé des découverts sur le compte courant lors de l'année précédente (en Kilos Francs).
- NBPR: Nombre de produits de la banque utilisés en plus du compte courant.
- NEMP: Nombre d'emprunts divers effectués lors des cinq dernières années.
- MEMP: Montant total des emprunts effectués lors des cinq dernières années (en K.F).
- VADD: Pourcentage de variation des dépôts d'épargne (pour les douze derniers mois)
- DEPO: Montant total des dépôts sur les comptes d'épargne effectués lors de l'année précédente (en K.F).
- RETR: Montant total des retraits sur les comptes d'épargne effectués lors de l'année précédente (en K.F).
- VARR: Pourcentage de variation des retraits sur les comptes d'épargne (pour les douze derniers mois).
- TAIL: Taille du ménage du titulaire du compte courant.
- AGE: Age du client titulaire du compte courant.

Dans ces variables ci-dessus, on se rend compte que les deux dernières sont prises en compte comme des variables supplémentaires.

Pour mieux avoir des bonnes représentations de données, il est nécessaires de suivre les quatre (04) étapes suivantes:

1. Description des données:

On détermine les valeurs manquantes et valeurs aberrantes. On déduit les différentes caractéristiques du données (i.e. Moyenne, Variance ...).

2. Analyse Bivariée:

On trouve la relation entre les variables (i.e. Matrice de corrélations ...).

3. Mise en échelle:

On standardise les données en centrant et réduisant pour éviter l'effet de tailles.

4. On construit l'objet A.C.P:

On poursuit au choix de nombres des axes factorielles avec l'un des critères des axes (i.e. Critère de coudes, de Kaiser, de pas de variances expliquées)

BUT:

1. L'ACP permet de réduire la dimension des données.
2. L'ACP permet de répondre à deux (02) objectifs principaux:
 - Quelles sont les relations multivariées entre les variables ?
 - Quelles sont les individus qui se ressemblent ? et Quelles sont les individus qui s'opposent ?

II) BUTS

Les objectifs de l'ACP sur cette base de données sont donc:

1. L'ACP permettra d'identifier les activités bancaire (variables) qui sont les plus fortement corrélées entre elles, de déterminer les activités les plus influentes pour le résultat ainsi qu'aux groupes d'activités qui émergent côte à côte.
2. L'ACP aidera d'identifier des groupes de clients (groupes d'individus) avec des profils bancaires similaires, de découvrir les clients (individus) qui se distinguent dans certaines activités (variables), et de visualiser des dispersions des clients en fonction de leur points fort et/ou points faibles sur leurs activités bancaires.

III) ETAPES

```
library(readxl)
library(FactoMineR) # PCA, dimdesc
library(factoextra) # get_eigenvalue, fviz_var, fviz_ind
library(gridExtra)
library(cowplot)
library(corrplot)
library(ggplot2)
library(psych)
```

1) Etape 1: Importation et description des données

a) Importation de données

```
BANQUE <- read_excel("D:/JEAN RENE/BANQUE.xlsx")
data = BANQUE[,-1]
data
```

```
# A tibble: 50 x 13
  SOLD CHEQ NDEC MDEC NBPR NEMP MEMP VADD DEPO RETR VARR TAIL AGE
  <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1  2305   253     7  2.3     0     1  8.5    -2   3.1  0.7     3     1    22
2 15259  1024     0  0.0     3     1  25     9 500     0     0     3    45
3  1236   156    10  5.4     1     0  0     3   6     2     1     1    19
4  8241   455     1  0.1     6     4 210     4  32    36     3     2    62
5  6210  1022     2  0.3     5     3 113     3 150   80.5    2     2    36
6  6871   321     1   3     6     4 200     3 125    98     3     2    31
7  1580   150     9  6.1     2     1   8     2   6.5   5.5    1     1    25
8  9630   562     1   4     5     3 111     4 225.  110.    2     1    28
9  4230    63     3  2.7     2     0   0     1   5.1   20     3     1    24
10 3620    84     5  9.8     1     1  81    -3   7.2   3.1    8     2    36
# i 40 more rows
```

b) Catégories des données

```
# Données actives
data_active = data[, 1:11]

#Données supplémentaires
data_supp = data[,12:13]
head(data_supp)
```

```
# A tibble: 6 x 2
  TAIL AGE
  <dbl> <dbl>
1     1   22
2     3   45
3     1   19
4     2   62
5     2   36
6     2   31
```

c) Analyse des données manquantes

```
# Fonction pour calculer la proportion de valeurs manquantes par variable
prop_val_manq = function(data){
  #Calcul du nombre de valeurs manquantes par colonne
  nbre_val_manq = sapply(data, function(x) sum(is.na(x)))

  #Calcul de la proportion de valeurs manquantes
  prop_manq = nbre_val_manq/nrow(data)

  #Création d'un dataframe pour le résultat
  resultat = data.frame(Nombre = nbre_val_manq, Proportion=prop_manq)

  return(resultat) }

#Utilisation de la fonction avec votre base de données
resultat = prop_val_manq(data)

#Affichage du résultat

resultat
```

	Nombre	Proportion
SOLD	0	0
CHEQ	0	0
NDEC	0	0
MDEC	0	0
NBPR	0	0
NEMP	0	0
MEMP	0	0
VADD	0	0
DEPO	0	0
RETR	0	0
VARR	0	0
TAIL	0	0
AGEC	0	0

Il n'y a pas de valeurs manquantes donc.

d) Analyse des variables quantitatives

i) Description des variables actives

```
# Moyenne
summary(data)
```

SOLD		CHEQ		NDEC		MDEC		NBPR	
Min.	: 231	Min.	: 24.0	Min.	: 0.0	Min.	:0.000	Min.	:0.00
1st Qu.:	3654	1st Qu.:	150.5	1st Qu.:	0.0	1st Qu.:	0.000	1st Qu.:	2.00
Median :	6016	Median :	394.0	Median :	1.0	Median :	0.300	Median :	3.00
Mean :	10870	Mean :	569.9	Mean :	1.8	Mean :	1.542	Mean :	3.04
3rd Qu.:	11758	3rd Qu.:	960.0	3rd Qu.:	2.0	3rd Qu.:	2.600	3rd Qu.:	4.00
Max.	:85214	Max.	:2360.0	Max.	:12.0	Max.	:9.800	Max.	:6.00

NEMP		MEMP		VADD		DEPO	
Min.	: 0.00	Min.	: 0.00	Min.	: -3.0	Min.	: 0.10
1st Qu.:	0.00	1st Qu.:	0.00	1st Qu.:	-1.0	1st Qu.:	14.78
Median :	1.00	Median :	11.75	Median :	3.0	Median :	112.55
Mean :	2.04	Mean :	58.07	Mean :	3.7	Mean :	223.18
3rd Qu.:	3.00	3rd Qu.:	110.08	3rd Qu.:	7.5	3rd Qu.:	403.95
Max.	:30.00	Max.	:310.00	Max.	:15.0	Max.	:916.20

RETR		VARR		TAIL		AGEC	
Min.	: 0.00	Min.	: -3.0	Min.	: 1.00	Min.	: 18.00
1st Qu.:	0.85	1st Qu.:	0.0	1st Qu.:	2.00	1st Qu.:	28.25
Median :	9.60	Median :	2.0	Median :	2.50	Median :	39.50
Mean :	37.25	Mean :	1.8	Mean :	2.78	Mean :	39.92
3rd Qu.:	79.25	3rd Qu.:	3.0	3rd Qu.:	3.75	3rd Qu.:	49.00
Max.	:253.70	Max.	: 9.0	Max.	:9.00	Max.	:78.00

ii) Moyennes et ecart-types des variables actives

```
# Variables actives
moyen_active = sapply(data_active, mean) #ou apply(data,2, mean)
sd_active = sapply(data_active, sd) #Ecart-type

df_moyen_sd_active = data.frame(Moyenne = moyen_active, Ecart_type=sd_active)
df_moyen_sd_active
```

	Moyenne	Ecart_type
SOLD	10869.520	16017.194342
CHEQ	569.860	536.185203
NDEC	1.800	2.878492
MDEC	1.542	2.395156
NBPR	3.040	1.713809
NEMP	2.040	4.393687

MEMP	58.072	81.576722
VADD	3.700	4.807520
DEPO	223.176	268.597581
RETR	37.254	51.422973
VARR	1.800	2.490799

iii) Moyennes et ecart-types des variables supplémentaires

```
# Variables supplémentaires
moyen_supp = sapply(data_supp, mean) #ou apply(data,2, mean)
sd_supp = sapply(data_supp, sd) #Ecart-type

df_moyen_sd_supp = data.frame(Moyenne = moyen_supp, Ecart_type=sd_supp)
df_moyen_sd_supp
```


	Moyenne	Ecart_type
TAIL	2.78	1.705812
AGEC	39.92	14.146233

2) Etape: Analyse des corrélations entre les variables actives

```
# Charger les packages

#Calculer la matrice de corrélation
matrix_corr = cor(data_active, use = "complete.obs")

# Créer la heatmap de corrélation
corrplot(matrix_corr, method = "color",
          type = "upper", order="hclust",
          tl.col = "black", tl.srt = 45,
          addCoef.col = "black", #Couleur des coefficients
          cl.pos = "n", # Position de la légende de couleur
          cl.cex = 1.2, #Taille de la legende de couleur
          addCoefasPercent = TRUE, #Afficher les coefficients en pourcentage
          number.cex = 0.8 #Taille des chiffres des coefficients
)
```

Interpretations:

- Plus la couleur est bleu, plus la corrélation est positive.
- Plus la couleur est rouge, plus la corrélation est négative.

3) Etape 3: Standardisation des données

```
# Centrer et réduire les données
data_scaled = scale(data_active, center=TRUE, scale = TRUE)
head(data_scaled)
```

	SOLD	CHEQ	NDEC	MDEC	NBPR	NEMP
[1,]	-0.5347079	-0.5909525	1.80650167	0.3164721	-1.77382613	-0.2367032
[2,]	0.2740480	0.8469835	-0.62532750	-0.6437994	-0.02333982	-0.2367032
[3,]	-0.6014487	-0.7718602	2.84871417	1.6107511	-1.19033069	-0.4643025
[4,]	-0.1641061	-0.2142170	-0.27792333	-0.6020485	1.72714650	0.4460945
[5,]	-0.2909074	0.8432534	0.06948083	-0.5185466	1.14365106	0.2184953
[6,]	-0.2496392	-0.4641307	-0.27792333	0.6087287	1.72714650	0.4460945


	MEMP	VADD	DEPO	RETR	VARR
[1,]	-0.6076733	-1.18564259	-0.8193521	-0.71084961	0.48177304
[2,]	-0.4054098	1.10243960	1.0306273	-0.72446220	-0.72265956


```
[3,] -0.7118697 -0.14560523 -0.8085553 -0.68556908 -0.32118203
[4,]  1.8623940  0.06240224 -0.7117562 -0.02438599  0.48177304
[5,]  0.6733293 -0.14560523 -0.2724373  0.84098600  0.08029551
[6,]  1.7398100 -0.14560523 -0.3655133  1.18130082  0.48177304
```

4) Etape 4: Réalisation de l'ACP avec FactoMineR

```
library(FactoMineR)

acp_active = PCA(data_scaled ,graph=TRUE)
```





```
#ou bien  acp_active = PCA(data_active, scale.unit=TRUE ,graph=TRUE)
acp_active
```

****Results for the Principal Component Analysis (PCA)****

The analysis was performed on 50 individuals, described by 11 variables

*The results are available in the following objects:

	name	description
1	"\$eig"	"eigenvalues"
2	"\$var"	"results for the variables"
3	"\$var\$coord"	"coord. for the variables"
4	"\$var\$cor"	"correlations variables - dimensions"
5	"\$var\$cos2"	"cos2 for the variables"
6	"\$var\$contrib"	"contributions of the variables"
7	"\$ind"	"results for the individuals"
8	"\$ind\$coord"	"coord. for the individuals"
9	"\$ind\$cos2"	"cos2 for the individuals"
10	"\$ind\$contrib"	"contributions of the individuals"
11	"\$call"	"summary statistics"
12	"\$call\$centre"	"mean of the variables"
13	"\$call\$ecart.type"	"standard error of the variables"
14	"\$call\$row.w"	"weights for the individuals"
15	"\$call\$col.w"	"weights for the variables"

IV) ANALYSE DES VARIABLES

1) Choix du nombre d'axe factoriel

Tout d'abord, on va chercher les valeurs propres données par l'objet `$acp_active$` crée ci-dessus. En effet, ce sont les valeurs propres de la matrice de corrélations du donnée active.

```
eigen_vals = acp_active$eig
eigen_vals
```

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	3.48173230	31.6521118	31.65211
comp 2	3.02673746	27.5157951	59.16791
comp 3	1.17447853	10.6770775	69.84498
comp 4	0.98976315	8.9978468	78.84283
comp 5	0.85418621	7.7653292	86.60816
comp 6	0.52458970	4.7689972	91.37716
comp 7	0.33943630	3.0857846	94.46294
comp 8	0.22714474	2.0649522	96.52789
comp 9	0.20189513	1.8354103	98.36330
comp 10	0.10190676	0.9264251	99.28973
comp 11	0.07812972	0.7102702	100.00000


On remarque que les valeurs propres sont **triés de façon décroissante**. Cela est dû au fait que les premières axes devront contenir le maximum d'information.

Le barplot suivant va expliquer visuellement ce concept d'information contenue dans chacun d'axe.

```
barplot(eigen_vals[,2], names.arg = 1:nrow(eigen_vals),
        main = "Pourcentage de la variance expliquée",
        xlab = "Composantes principales",
        col = "steelblue"
)
```

```
# Ajouter des "Connected line segments" dans les bar
lines(x=1:nrow(eigen_vals), eigen_vals[,2], type="b", pch=19, col="red")
```

Pourcentage de la variance expliquée



Remarques:

Chaque bar ci-dessus correspond aux quantités d'informations que chaque axe contient. A partir de cette graphique, il faut procéder maintenant au choix des nombres des axes principales en utilisant:

- **La règle de Coudes:** A partir de quel moment les variances expliquées décroissent significativement? Ici, on voit que cela se passe sur la deuxième axe. Donc on devrait retenir les deux premières; mais ici cela nous donne seulement 59.17% de l'information.
- **Technique de la variance expliquée:** On choisit les axes qui expliquent au moins 80% de l'information. Ici, ça nous donne les cinq premières axes avec 86.61%

1. Nombres d'axes:

Le critère 'relatif' nommé aussi **Technique de la variance expliquée** nous a exposé le fait qu'on doit retenir les cinq (05) premières axes factorielles. Ces axes ont respectivement les valeurs propres suivants:

- $\lambda_1 = 3.48173230$ avec 31.65% d'informations.
- $\lambda_2 = 3.02673746$ avec 27.52% d'informations.
- $\lambda_3 = 1.17447853$ avec 10.68% d'informations.
- $\lambda_4 = 0.98976315$ avec 9.00% d'informations.
- $\lambda_5 = 0.85418621$ avec 7.77% d'informations.

Dans toute la suite, on va faire l'analyse dans les deux premières axes principaux PC1 et PC2.

3) Coordonnées des variables sur les axes

```
acp_active$var$coord
```

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
SOLD	0.77637438	-0.16340790	0.30092382	0.13130448	0.17301637
CHEQ	0.52097971	0.17858855	0.18705641	-0.07057114	0.76517038
NDEC	-0.65525534	-0.34462919	0.57369978	-0.13916926	0.03217370
MDEC	-0.58164706	-0.15395018	0.73168170	0.13139344	-0.04846089
NBPR	0.25432236	0.86183002	0.19986706	0.08301410	-0.09753335
NEMP	-0.02493131	0.56155147	0.05337600	-0.68067522	0.08716044
MEMP	-0.06195403	0.93404486	0.15822622	0.12901238	-0.08040879
VADD	0.84918739	-0.08968828	0.22424196	0.14313990	-0.28812875
DEPO	0.89116116	-0.22359001	0.18244287	0.10367956	-0.14463438
RETR	-0.05224068	0.88985593	0.08055246	0.10997113	-0.13122123
VARR	-0.50271873	0.21274546	-0.16295335	0.63302706	0.30108251

La qualité de représentation d'une variable par rapport à l'axe est assuré par le **cos2** et la **contribution**.

4) Cos2 des variables

```
# Valeurs de cosinus carrées des variables
acp_active$var$cos2
```

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
SOLD	0.602757185	0.026702141	0.090555147	0.017240867	0.029934663
CHEQ	0.271419860	0.031893869	0.034990102	0.004980286	0.585485704
NDEC	0.429359565	0.118769282	0.329131438	0.019368084	0.001035147
MDEC	0.338313303	0.023700659	0.535358108	0.017264237	0.002348458
NBPR	0.064679864	0.742750975	0.039946843	0.006891342	0.009512755
NEMP	0.000621570	0.315340059	0.002848998	0.463318750	0.007596942
MEMP	0.003838302	0.872439800	0.025035538	0.016644195	0.006465573
VADD	0.721119222	0.008043987	0.050284457	0.020489031	0.083018175
DEPO	0.794168219	0.049992491	0.033285401	0.010749452	0.020919104

```
RETR 0.002729088 0.791843568 0.006488699 0.012093650 0.017219012
VARR 0.252726123 0.045260633 0.026553796 0.400723254 0.090650677
```

```
# COSINUS CARREES GRAPHIQUEMENT
```


```
# Cosinus carré des variables sur la première composante principale (PC1)
```

```
cos2_var1 = fviz_cos2(acp_active, choice = "var", axes = 1) +  
  ggtitle("Qualité sur PC1") #la représentation des variables sur la PC1 (cos2)"
```

```
# Cosinus carré des variables sur la deuxième composante principale (PC2)
```

```
cos2_var2 = fviz_cos2(acp_active, choice = "var", axes = 2) +  
  ggtitle("Qualité sur PC2")# la représentation des variables sur la PC2 (cos2)"
```

```
plot_grid(cos2_var1, cos2_var2)
```



4) Contribution des variables

```
# Valeurs des contributions des variables
```

```
acp_active$var$contrib
```

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
SOLD	17.31199106	0.8822087	7.7102429	1.7419185	3.5044657
CHEQ	7.79554074	1.0537375	2.9792032	0.5031796	68.5430996
NDEC	12.33177993	3.9240034	28.0236233	1.9568403	0.1211852
MDEC	9.71680974	0.7830431	45.5826220	1.7442796	0.2749351
NBPR	1.85769204	24.5396564	3.4012408	0.6962617	1.1136629
NEMP	0.01785232	10.4184807	0.2425756	46.8110731	0.8893777
MEMP	0.11024114	28.8244293	2.1316301	1.6816341	0.7569278
VADD	20.71150679	0.2657643	4.2814283	2.0700943	9.7189786
DEPO	22.80957152	1.6516956	2.8340578	1.0860631	2.4490099
RETR	0.07838306	26.1616205	0.5524749	1.2218731	2.0158382
VARR	7.25863165	1.4953604	2.2609009	40.4867826	10.6125194

```
# CONTRIBUTIONS GRAPHIQUEMENT
```

```
#On utilise maintenant le library(factoExtra)
```

```
library(factoextra)
```


```
# Contributions des variables dans la première composante principale (PC1)
```

```
contrib2_var1 = fviz_contrib(acp_active, choice = "var", axes = 1) #ou avec top = 10
```

```
# Contributions des variables dans la deuxième composante principale (PC2)
```

```
contrib2_var2 = fviz_contrib(acp_active, choice = "var", axes = 2)#ou avec top = 10
```

```
plot_grid(contrib2_var1, contrib2_var2)
```

Notations:


- Le trait rouge discontinue représente la contribution moyenne.
- On analyse(interprétation) les variables qui ont une contribution supérieur à la moyenne, mais les restent n'ont pas une bonne contribution.

5) Représentation du cercle de corrélation sur le premier plan factoriel

Le but est de déterminer les variables qui sont corrélées entre elles.


```
# Créer le graphique du cercle de corrélation avec cos2
cercle_cos2 = fviz_pca_var(acp_active,
  col.var = "cos2",
  #Utiliser la qualité de représentation (cos2) pour la couleur, on peut utiliser
  gradient.cols = c("#00AF88", "#E78800", "#FC4E07"), #palette de couleurs
  repel = TRUE, #Eviter chevauchement des étiquettes
  title = "Cercle de Corrélation des Variables avec cos2")

cercle_cos2
```



```
#plot_grid(cercle_cos2, cercle_contrib, labels = "Cercle de Corrélation des Variables sur le
```

```
# Créer le ntribgraphique du cercle de corrélation avec contrib
cercle_contrib = fviz_pca_var(acp_active,
  col.var = "contrib",
  #Utiliser la qualité de représentation (cos2) pour la couleur, on peut utiliser
  gradient.cols = c("#00AF88", "#E78800", "#FC4E07"), #palette de couleurs
  repel = TRUE, #Eviter chevauchement des étiquettes
  title = "Cercle de Corrélation des Variables avec contrib")
cercle_contrib
```



Explications

1. Plus la variable se rapproche du bord du cercle, plus cette variable est mieux représentée.
2. Une variable mieux représentée par les axes est déterminée par le $\cos^2$. Une qualité supérieure correspond à un $\cos^2$ supérieur.
3. Toutes les variables qui ont la même direction sur ce cercle de corrélation sont positivement corrélées. **Exemple: Un client qui a fait un retrait important sur son compte d'épargne lors de l'année précédente a sûrement emprunté une somme importante lors de cinq années précédente.**
4. En considérant le premier axe factoriel, les variables qui se trouvent dans le 1er demi-cercle de droite sont négativement corrélées avec celles du 2ème demi-cercle de gauche.
5. Mais quand on considère le deuxième axe factoriel, les variables qui se trouvent dans le 1er demi-cercle de haut sont négativement corrélées avec celles du 2ème demi-cercle de bas.
6. Le terme négativement corrélée veut dire que: lorsqu'un individu met une importance hausse dans une activité (variable) alors il admet le contraire dans l'activité (variable) négativement corrélée avec celle-ci.

Interprétations

1. Les variables SOLD, DEPO, VADD et CHEQ sont positivement corrélées avec le premier axe factoriel mais CHEQ n'est pas bien représenté.
2. Les variables NDEC, MDEC et VARR sont négativement corrélées avec le premier axe factoriel mais seule NDEC est bien représentée.
3. Les variables NEMP, RETR, NBPR et MEMP sont positivement corrélées avec le deuxième axe factoriel mais NEMP est mal représentée.

V) ANALYSE DES INDIVIDUS

Dans cette partie, on cherche les individus qui illustrent les propos interprétés dans l'Analyse des variables.

1) Coordonnées des individus sur les axes

```
head(acp_active$ind$coord)
```

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
1	-2.4038970	-1.8343438	-0.01671998	-0.33580577	0.4347720
2	2.0133833	-0.7190124	-0.16377484	-0.18982293	0.1438370
3	-2.4721738	-2.1514344	1.79813386	-0.47448980	-0.4328668
4	-0.1170392	2.2586145	-0.20697285	0.27473491	-0.2384645
5	0.1421135	1.6435772	0.04635169	-0.04894257	0.5145744
6	-0.5632969	2.6549374	0.63906747	0.56755953	-0.6791537

3) Cos2 des individus

```
# Valeurs de cosinus carrées des individus
head(acp_active$ind$cos2)
```

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
1	0.545320157	0.31752749	0.0000263810	0.0106413358	0.017837869
2	0.772349771	0.09849947	0.0051104067	0.0068652832	0.003941868
3	0.397847249	0.30131071	0.2104759071	0.0146558872	0.012197391
4	0.001697923	0.63232324	0.0053098427	0.0093558362	0.007048594
5	0.005367264	0.71789764	0.0005709703	0.0006365843	0.070368555
6	0.035673001	0.79245301	0.0459154002	0.0362149421	0.051856244


```
library(factoextra)

# COSINUS CARREES GRAPHIQUEMENT

# Cosinus carré des individus sur la première composante principale (PC1)
cos2_ind1 = fviz_cos2(acp_active, choice = "ind", axes = 1, top=10) +
  ggtitle("Qualité sur PC1")# la représentation des individus sur la PC1 (cos2)

# Cosinus carré des individus sur la deuxième composante principale (PC2)
cos2_ind2 = fviz_cos2(acp_active, choice = "ind", axes = 2, top=10) +
  ggtitle("Qualité sur PC2")# la représentation des individus sur la PC2 (cos2)

plot_grid(cos2_ind1, cos2_ind2)
```



3) Contribution des individus

```
# Valeurs des contributions des individus
head(acp_active$ind$contrib)
```

```
Dim.1    Dim.2    Dim.3    Dim.4    Dim.5
```

```

1 3.319451441 2.223396 0.0004760541 0.22786363 0.44258895
2 2.328560565 0.341608 0.0456750758 0.07281085 0.04844159
3 3.510691186 3.058521 5.5059080589 0.45493828 0.43871858
4 0.007868602 3.370850 0.0729477090 0.15251987 0.13314505
5 0.011601263 1.784989 0.0036586099 0.00484030 0.61997442
6 0.182267531 4.657617 0.6954698930 0.65091092 1.07997460

```

```
# CONTRIBUTIONS GRAPHIQUEMENT
```

```
# Contributions des individus dans la première composante principale (PC1)
```


```
contrib2_ind1 = fviz_contrib(acp_active, choice = "ind", axes = 1) #ou avec top = 10
```

```
# Contributions des individus dans la deuxième composante principale (PC2)
```

```
contrib2_ind2 = fviz_contrib(acp_active, choice = "ind", axes = 2) #ou avec top = 10
```


```
contrib2_ind1
```

Contribution of individuals to Dim-1



```
contrib2_ind2
```


Contribution of individuals to Dim-2



4) Représentation des individus sur le premier plan factoriel

```
#On utilise maintenant le library(factoExtra)
library(factoextra)

# Créer le graphique du cercle de corrélation
fviz_pca_ind(acp_active, # Sur l'individu maintenant
             col.ind = "cos2",
             title = "Les individus sur le premier plan factoriel")+
  scale_color_gradient2(low="blue", mid="gray", high = "red", midpoint = 0.50)+
  theme_minimal()
```



Interprétations

1. Dimension 1:

- Cette dimension oppose les clients tels que le numéro 2,38,49,21,27 (à droite du graphe, caractérisé par une coordonnée fortement positive sur l'axe) aux clients numéros 9,1,3,7 (à gauche du graphe, caractérisés par une coordonnée fortement négative sur l'axe)

2. Dimension 2:

- Cette dimension a seulement une corrélation fortement positive aux clients tels que 6,41,37,5,45,29.

VI) SUPERPOSITION DES INDIVIDUS ET VARIABLES

Comme la taille des individus est grande, on va filtrer seulement ceux qui sont avec des cos2 supérieur 50%


```
#Filtration des individus avec cos2 >50%
indi_cos2 = apply(acp_active$ind$cos2, 1, max)>0.5 # Tableau de True et de False

#Filtration des variables avec cos2 >50%
```



```
var_cos2 = apply(acp_active$var$cos2, 1, max)>0.5 # Tableau de True et de False

# Créer un graphique combiné des individus et des variables
fviz_pca_biplot(acp_active,
  select.ind = list(cos2=0.5), #Selectionner les individus avec cos2>50%
  select.var= list(cos2=0.5), #Selectionner les variables avec cos2>50%
  repel = TRUE, #Eviter le chevauchement des étiquettes
  title = "Biplot des individus et des variables (cos2>50%) ",
  col.ind = "blue", #Couleur des individus
  col.var = "red", #Couleur des variables
)
```



CONCLUSION

Interprétations:

1. Dimension 1

Les clients tels que 12,26,22,38,42 ... qui se trouvent à droite de l'axe 1:

- ont des valeurs plus importantes pour les activités bancaires DEPO, VADD et SOLD;

- ont des valeurs moins importantes pour NDEC.

Contrairement, les clients tels que 10,14,3,1,7 ... qui se trouvent à gauche de l'axe 1:

- ont des valeurs plus importantes pour l'activité bancaire NDEC
- ont des valeurs moins importantes pour DEPO, VADD et SOLD.

2. Dimension 2

Les clients tels que 20,41,45,6,37,23 ... qui se trouvent en haut de l'axe 2:



- ont des valeurs plus importantes pour les activités bancaires MEMP, RETR, NBPR.

VII) AJOUT DES VARIABLES SUPPLEMENTAIRES

- Par définition, une variable supplémentaire est une variable qu'on peut analyser, mais elle ne participe pas à la construction des axes factorielles. En général, les variables qualitatives se mettent toujours en variables supplémentaires.
- Les variables quantitatives supplémentaires vont être représentées dans les nuages des variables.
- Contrairement, les variables qualitatives supplémentaires sont souvent représentées dans les nuages des individus. En effet, on fait toujours les représentations des modalités de ces variables qualitatives supplémentaires dans les graphes des individus.

1) ACP avec les variables supplémentaires

```
acp_avec_supp = PCA(data,
                     quanti.sup = c(12,13),
                     # quali.sup = vide , pas de variable qualitative supplémentaire
                     graph=TRUE)
```



Et on voit qu'il n'y a pas des modalités de variables qualitatives supplémentaires affichées dans les nuages des individus, tandis que deux variables quantitatives supplémentaires (en bleu) sont belle et bien affichées dans les nuages des variables.

2) Qualité de représentations:

```
# Qualité des variables qualitative supplementaires:  
acp_avec_supp$quali
```

NULL

Cela met en evidence les propos ci-dessus. Si cela était non nul, on devrait avoir un attribut que l'on appelle `$v.test`. Ceci est le résultat d'un test si cette variable est significative pour expliquer l'axe en question. En effet, elle est significative (il y a une liaison) si $|\$v.test| > 1.96$

```
# Qualité des variables quantitatives supplementaires:  
acp_avec_supp$quanti.sup
```

```
$coord  
      Dim.1      Dim.2      Dim.3      Dim.4      Dim.5  
TAIL 0.3597806 0.06622889 -0.06530572 -0.07974372 0.15414453  
AGEC 0.3629443 0.26930998 -0.11139645 -0.03643267 -0.08787171
```

```
$cor  
      Dim.1      Dim.2      Dim.3      Dim.4      Dim.5  
TAIL 0.3597806 0.06622889 -0.06530572 -0.07974372 0.15414453  
AGEC 0.3629443 0.26930998 -0.11139645 -0.03643267 -0.08787171
```

```
$cos2  
      Dim.1      Dim.2      Dim.3      Dim.4      Dim.5  
TAIL 0.1294420 0.004386266 0.004264837 0.006359061 0.023760535  
AGEC 0.1317285 0.072527867 0.012409170 0.001327339 0.007721438
```

Et ici, sur les quantitatives supplémentaire, on a:

Plus la corrélations `$cor` est élevée, plus la variable est liée à l'axe en question.

2) Tests de corrélations entre les variables et axes

```
resume_desc = dimdesc(acp_avec_supp, axes = 1:5, proba = 0.05)  
resume_desc
```

\$Dim.1

Link between the variable and the continuous variables (R-square)

```
=====
      correlation      p.value
DEPO   0.8911612 4.277359e-18
VADD   0.8491874 6.558444e-15
SOLD   0.7763744 3.473580e-11
CHEQ   0.5209797 1.049088e-04
AGEC   0.3629443 9.584044e-03
TAIL   0.3597806 1.028035e-02
VARR  -0.5027187 1.988239e-04
MDEC  -0.5816471 9.428121e-06
NDEC  -0.6552553 2.423595e-07
```

\$Dim.2

Link between the variable and the continuous variables (R-square)

```
=====
      correlation      p.value
MEMP   0.9340449 4.213017e-23
RETR   0.8898559 5.608396e-18
NBPR   0.8618300 9.314630e-16
NEMP   0.5615515 2.207272e-05
NDEC  -0.3446292 1.425166e-02
```

\$Dim.3

Link between the variable and the continuous variables (R-square)

```
=====
      correlation      p.value
MDEC   0.7316817 1.578801e-09
NDEC   0.5736998 1.328719e-05
SOLD   0.3009238 3.370968e-02
```

\$Dim.4

Link between the variable and the continuous variables (R-square)

```
=====
      correlation      p.value
VARR   0.6330271 8.100732e-07
NEMP  -0.6806752 5.367294e-08
```

\$Dim.5

Link between the variable and the continuous variables (R-square)

```
=====
      correlation      p.value
CHEQ    0.7651704 9.778985e-11
VARR    0.3010825 3.361147e-02
VADD   -0.2881287 4.244795e-02
```

Les tests précédentes se basent sur:

H0: var et axe decorréées vs H1: var et axe corrélées

- La variable X_i et l'axe PC_i corrélées (i.e: On rejette H0) si $p - value < 0.05$.
- Mais elles sont corrélées si $p - value > 0.05$.